

AutoEval Lab Assignment of AR Prediction

自回归语言模型的 Token 预测与概率分析实验

Lab focus

本实验只要求掌握 AR (Autoregressive) 语言模型如何根据已有上下文预测下一个 Token，以及如何从模型输出中提取 Token 的概率。无需训练模型，也无需深入推导 Transformer 结构。

1 Learning Objectives

完成本实验后，你应能够：

- 解释自回归语言模型的 next-token prediction 过程；
- 从 logits 中获得指定 Token 的 probability 与 log probability；
- 计算逐 Token 条件概率、总 log probability 和平均 NLL；
- 识别 Tokenization、前导空格和文本长度对概率比较的影响。

2 Experimental Setup

使用 Python 调用一个开源自回归语言模型，例如 GPT-2、Qwen、Llama 等。推荐使用 Hugging Face Transformers 与 PyTorch。请在报告中注明模型名称、版本和运行环境。

Required tools	Python, PyTorch, Transformers
Model output	input_ids, logits, token probabilities
Submission	Jupyter Notebook 或 Python 项目 + 实验报告

3 Core Tasks

Task A — Next-token prediction

给定上下文 The capital of France is, 输出 Top-10 Token: Token 文本、Token ID、probability、log probability，并解释值得注意的现象。

Task B — Candidate Token probability

对 Paris、London、Berlin 提取下一个 Token 的概率并排序；检查带空格与不带空格的 Token 是否对应不同 ID。

Task C — Token-level scoring

对 The capital of France is Paris. 输出每个位置的 Token、Token ID、上下文及条件概率。位置 t 的概率必须来自前缀 $x_{<t}$ 。

AutoEval Lab Assignment of AR Prediction

Implementation, analysis and submission requirements

4 Required Computation

对文本序列 $x_1, x_2, \dots, x_T$ ，计算：

$P(x_t x_{1:t-1})$	第 t 个 Token 在此前缀下的概率
$\log P(x) = \sum \log P(x_t x_{1:t-1})$	总 log probability
$NLL = -(1/T) \sum \log P(x_t x_{1:t-1})$	平均负对数似然
$\text{Perplexity} = \exp(NLL)$	可选：困惑度

建议展示逐 Token 表格，并比较至少两段文本。不同长度文本不要只比较总概率，应同时报告平均 NLL 或困惑度。

5 Deliverables

- 可从头运行的 Notebook 或 Python 项目；
- 不超过 2 页的实验报告，说明方法、结果、观察与局限；
- 包含 Top-10、候选 Token 和完整文本逐 Token 概率的结果表；
- README：运行命令、依赖版本、模型名称及是否需要 GPU。

6 Questions for Discussion

- logits、probability 和 log probability 有何区别？为什么使用 softmax？
- 为什么 Paris 与 Paris 可能不同？一个词拆成多个 Token 时如何计算词概率？
- 模型概率能否直接理解为事实正确率？为什么？
- temperature 是否改变 probability distribution 和原始 logits？（可选）

7 Grading Rubric

Category	Points	Criteria
Model inference & Tokenization	20	正确编码文本并获得 logits
Top-k & candidate probabilities	20	概率提取正确，处理空格/拆分
Token-level log probability	25	逐 Token 对齐、公式和结果正确
Text scoring & analysis	20	NLL/困惑度及现象分析
Reproducibility & writing	15	代码可运行，报告清晰规范

Optional extension：比较两个模型的困惑度；分析事实正确/错误陈述的概率差异；或实现一个简单的文本自然度打分器。